

작은 모델을, 실서비스에 맞게 교정하다

1.3B 한국어 모델의 자연스러움은 보존하고, 구조화 사실 읽기만 정밀하게 교정

STARTING POINT

K0-INSTRUCT

Kanana 2 · 1.291B · 한국어 대화 품질과 후속 설명
능력이 좋은 기준 모델

GROUNDING ADAPTER

SELECT

LoRA r=16

원국·기간 label을 정확히 읽고, 제공되지 않은
관계·예측을 만들지 않도록 교정

선정 결론

K0의 말하기 능력 + LoRA의 근거 교정

Full FT와 KI20 이어학습은 1차에서 제외 — 기반 능력 손실 위험과 비용을 줄이고 비교 가능성을 확보했습니다.

모델 선정 기준

- 01 자연스러운 한국어
K0의 장점 유지
- 02 구조 사실 정확도
JSON field 혼동 교정
- 03 단일 GPU 운용
16 GB 환경에서 반복 실험

KI20 = 실패 비교 baseline


목표는 '사주 지식 추가'가 아닙니다

실제 runtime JSON에서 필요한 사실만 골라 일반인이
이해할 말로 설명하는 행동 교정입니다.

02 경량화 방법 — 98.57%는 그대로


Base weight를 freeze하고, 작은 adapter만 학습·저장·교체합니다.

LoRA $r=16$ · 실제 파라미터



Rank ablation

$\alpha=32$ 고정



all-linear

RSLORA

dropout 0.05

bias none

adapter-only

독립 adapter이므로 K0·r8·r16·r32를 같은 조건에서 비교 가능

34분 59초

R16 · 2K · 1 epoch

4.34 GiB

학습 peak reserved

2.69 GiB

실제 추론 peak allocated

224 modules

LoRA 적용 linear layer

03 데이터셋 & 실제 학습 — 2,000행을 '실제 입력 형태'로


compact 요약본이 아니라 production-like full runtime snapshot을 그대로 학습했습니다.

FULL RUNTIME SNAPSHOT

원국 4주 + 일간·오행·음양·십신·지장간 + 기간 연/월/일 간지 + limitations·provenance

학습 데이터 구성

TOTAL 2,000



600개 원국 · 300개 날짜 · 학습과 분리된 dev 200

학습 recipe

2048

max_length

1 epoch

250 optimizer steps

5e-5

cosine LR

1 × 8

batch × grad accum

BF16

gradient checkpoint

LOSS

assistant only

TOKEN AUDIT · MAX

prompt 1,802 · answer 169 · rendered 1,960

TEACHER

초안

VALIDATOR

구조 fact

PEER

PASS

TOKEN

0 truncation

LORA

1 epoch

실험 한계 · 최종 draft는 Codex 2,000건, review는 Claude 191 + Codex 1,809 → cross-provider 계약 미충족, production 승격 금지

04 실사용 입·출력 — 정확한 구조에서 자연스러운 3줄로

DIAGNOSTIC · production=false

Dashboard v1.14 실제 GPU smoke · raw output 보존 · 자동 재작성 없음

REAL INPUT · 핵심 사실 발췌

natal

year / month 戊辰 / 甲子
day / hour 乙丑 / 壬午
day master 乙木

period · 2026-09-02

year / month 丙午 / 丙申
day 己卯

Q. 오늘의 흐름을 원국과 함께 이야기해줘

실제 호출 778 input tokens · full snapshot은 더 많은 field 포함



R16 RAW OUTPUT

원국에서 확인되는 일간은 乙이며,
일주는 乙丑입니다.

선택 날짜인 2026-09-02의 연간지는 丙午,
월간지는 丙申, 일진은 己卯입니다.

오늘의 흐름은 이 날짜 간지와 원국의 乙丑을
함께 참고할 수 있지만, 두 정보를 합쳐 특정한
사건이나 결과를 단정할 수는 없습니다.

16.7 s

peak 2.69 GiB

3 lines

no retry / rewrite

정확해진 부분

丙午=연간지 · 丙申=월간지 · 己卯=일진, 금지된 통근·신강약 생성
없음

남은 release blocker

원국 네 기둥 전체를 답변에서 생략 → warning, 진단 모델로만 유지

실서비스 계약

4K input + 4K output · native ≥8K · 후속 질문은 3줄·grounding PASS