

작은 모델을, 실서비스에 맞게 교정하다

1.3B 한국어 모델의 자연스러움은 보존하고, 구조화 사실 읽기만 정밀하게 교정

STARTING POINT

K0-INSTRUCT

Kanana 2 · 1.291B · 한국어 대화 품질과 후속 설명
능력이 좋은 기준 모델

GROUNDING ADAPTER

SELECT

LoRA r=16

원국·기간 label을 정확히 읽고, 제공되지 않은
관계·예측을 만들지 않도록 교정

선택 결론

K0의 말하기 능력 + LoRA의 근거 교정

Full FT와 K120 이어학습은 1차에서 제외 — 기반 능력 손실 위험과 비용을 줄이고 비교 가능성을 확보했습니다.

모델 선정 기준

01

자연스러운 한국어

K0의 장점 유지

02

구조 사실 정확도

JSON field 혼동 교정

03

단일 GPU 운용

16 GB 환경에서 반복 실험

K120 = 실패 비교 baseline

목표는 '사주 지식 추가'가 아닙니다

실제 runtime JSON에서 필요한 사실만 골라 일반인이
이해할 말로 설명하는 행동 교정입니다.

02 경량화 방법 — 98.57%는 그대로

Base weight를 freeze하고, 작은 adapter만 학습·저장·교체합니다.

LoRA $r=16$ · 실제 파라미터




18,677,760 / 1,310,156,032

Base 1.291B는 변경하지 않음

Rank ablation

$\alpha=32$ 고정

$r=8$



9.34M · 0.72%

$r=16$



18.68M · 1.43%

$r=32$



37.36M · 2.81%

all-linear

RSLORA

dropout 0.05

bias none

adapter-only

독립 adapter이므로 K0· $r=8$ · $r=16$ · $r=32$ 를 같은 조건에서 비교 가능

34분 59초

$R=16$ · 2K · 1 epoch

4.34 GiB

학습 peak reserved

2.69 GiB

실제 추론 peak allocated

224 modules

LoRA 적용 linear layer

03 데이터셋 & 실제 학습 — 2,000행을 '실제 입력 형태'로

compact 요약본이 아니라 production-like full runtime snapshot을 그대로 학습했습니다.

FULL RUNTIME SNAPSHOT

원국 4주 + 일간·오행·음양·십신·지장간 + 기간 연/월/일 간지 + limitations·provenance

학습 데이터 구성

TOTAL 2,000



600개 원국 · 300개 날짜 · 학습과 분리된 dev 200

학습 recipe

2048

max_length

1 epoch

250 optimizer steps

5e-5

cosine LR

1 × 8

batch × grad accum

BF16

gradient checkpoint

LOSS

assistant only

TOKEN AUDIT · MAX

prompt 1,802 · answer 169 · rendered 1,960

TEACHER

초안

VALIDATOR

구조 fact

PEER

PASS

TOKEN

0 truncation

LORA

1 epoch

실험 한계 · 최종 draft는 Codex 2,000건, review는 Claude 191 + Codex 1,809 → cross-provider 계약 미충족, production 승격 금지

04 실사용 입·출력 — 정확한 구조에서 자연스러운 3줄로

DIAGNOSTIC · production=false

Dashboard v1.14 실제 GPU smoke · raw output 보존 · 자동 재작성 없음

REAL INPUT · 핵심 사실 발췌

natal

year / month 戊辰 / 甲子

day / hour 乙丑 / 壬午

day master 乙木

period · 2026-09-02

year / month 丙午 / 丙申

day 己卯

Q. 오늘의 흐름을 원국과 함께 이야기해줘

실제 호출 778 input tokens · full snapshot은 더 많은 field 포함

R16 RAW OUTPUT

원국에서 확인되는 일간은 乙이며,
일주는 乙丑입니다.

선택 날짜인 2026-09-02의 연간지는 丙午,
월간지는 丙申, 일진은 己卯입니다.

오늘의 흐름은 이 날짜 간지와 원국의 乙丑을
함께 참고할 수 있지만, 두 정보를 합쳐 특정한
사건이나 결과를 단정할 수는 없습니다.

16.7 s

peak 2.69 GiB

3 lines

no retry / rewrite

정확해진 부분

丙午=연간지 · 丙申=월간지 · 己卯=일진, 금지된 통근·신강약 생성
없음

남은 release blocker

원국 네 기둥 전체를 답변에서 생략 → warning, 진단 모델로만 유지

실서비스 계약

4K input + 4K output · native ≥8K · 후속 질문은 3줄·grounding PASS